

Compte rendu de la semaine 3

Sujet du stage : Classification non supervisée d'une image satellite hyperspectrale

Travail effectué durant la semaine

Analyse exploratoire d'image hyperspectrale Indiane Pines

Cette première phase a pour objectif de **comprendre la structure des données hyperspectrales** avant l'application d'un algorithme de classification non supervisée

```
show-dataset_info.py > ...
1  import numpy as np
2  import matplotlib.pyplot as plt
3
4  data = np.load('C:\\Users\\AssaneThiao\\Documents\\internship\\dataset\\indianpinearray.npy') # Hyper
5  gt = np.load('C:\\Users\\AssaneThiao\\Documents\\internship\\dataset\\IPgt.npy') # Ground truth
6
7  print("=== Indian Pines Dataset Info ===")
8  print(f"Data shape: {data.shape} (Height, Width, Spectral Bands)")
9  print(f"Ground truth shape: {gt.shape} (Height, Width)")
10 print(f"Number of spectral bands: {data.shape[2]}")
11 print(f"Image dimensions: {data.shape[0]} x {data.shape[1]}")
12 print(f"Unique classes in ground truth: {np.unique(gt)}")
13 print(f"Total pixels: {data.shape[0] * data.shape[1]}")
14
15 # Show a single spectral band as a grayscale image
16 plt.figure(figsize=(6, 4))
17 plt.imshow(data[:, :, 30], cmap='gray')
18 plt.title('Band 30 (example spectral band)')
19 plt.axis('off')
20 plt.show()
21
22 # Show the ground truth map
23 plt.figure(figsize=(6, 4))
24 plt.imshow(gt, cmap='jet')
25 plt.title('Ground Truth (Land Cover Classes)')
26 plt.axis('off')
27 plt.show()
28
29 row, col = 60, 80
30 plt.figure(figsize=(8, 4))
31 plt.plot(data[row, col, :])
32 plt.title(f'Spectral Signature at Pixel ({row}, {col})')
33 plt.xlabel('Band')
34 plt.ylabel('Reflectance')
35 plt.show()
36
37
```

Les données utilisées sont issues du dataset **Indian Pines** :

- Une image hyperspectrale data
- Une carte de référence ground truth (gt)

Informations extraites

```
PS C:\Users\AssaneThiao\Documents\internship> python .\show-dataset_info.py
=== Indian Pines Dataset Info ===
Data shape: (145, 145, 200) (Height, Width, Spectral Bands)
Ground truth shape: (145, 145) (Height, Width)
Number of spectral bands: 200
Image dimensions: 145 x 145
Unique classes in ground truth: [ 0  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16]
Total pixels: 21025
PS C:\Users\AssaneThiao\Documents\internship> █
```

L'image hyperspectrale est alors un **cube de données 3D** :

- Axe 1 : hauteur
- Axe 2 : largeur
- Axe 3 : signatures spectrales (longueurs d'onde)

Donc, chaque pixel correspond donc à une signature spectrale complète.

Visualisation d'une bande spectrale

La bande spectrale 30 a été affichée en niveaux de gris.

Spectral band 30




Cette observation :

- Représente une seule longueur d'onde
- Permet de visualiser les variations spatiales d'intensité
- Ne contient qu'une partie de l'information globale

Visualisation de la vérité terrain

La ground truth a été affichée pour observer les classes réelles présentes dans la scène.

Ground Truth (Land Cover Classes)




Cette observation permet de distinguer:

- Plusieurs classes de couverture du sol qui sont présentes
- Les régions qui sont spatialement structurées
- Cette carte qui servira de référence pour l'évaluation future des algorithmes

Analyse d'un pixel (signature spectrale)

Un pixel (60, 80) a été sélectionné afin d'étudier son comportement spectral.



Cette visualisation met en évidence:

- Le pixel qui est représenté par un vecteur de 200 valeurs
- Ce vecteur qui correspond à sa **signature spectrale**
- Cette signature qui décrit la réponse du matériau selon les longueurs d'onde

Cette étape permet de conclure que l'image hyperspectrale est un ensemble de **vecteurs spectraux par pixel**, que la classification doit se faire dans un **espace de dimension élevée (200D)** et que la structure des données combine information spectrale (signature) et information spatiale (position)

2eme étape

Objectif : Construire une **classification non supervisée avec K-means** à partir de l'image hyperspectrale et l'évaluer avec la ground truth.

```

import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans

# Load data
data = np.load('C:\\Users\\AssaneThiao\\Documents\\internship\\dataset\\indianpinearray.npy')
gt = np.load('C:\\Users\\AssaneThiao\\Documents\\internship\\dataset\\IPgt.npy')

print("Image shape:", data.shape)
print("Ground truth shape:", gt.shape)

# Preprocessing
M, N, K = data.shape
X = data.reshape(M * N, K)
print("Dataset shape (pixels, bands):", X.shape)

# K-means clustering
n_clusters = 2 # à tester
kmeans = KMeans(n_clusters=n_clusters, random_state=0, n_init=20)
labels = kmeans.fit_predict(X)

# Reconstruction image
classification = labels.reshape(M, N)

# Visualisation
plt.figure(figsize=(6,5))
plt.imshow(classification, cmap='jet')
plt.title("K-means Classification")
plt.axis('off')
plt.show()

plt.figure(figsize=(6,5))
plt.imshow(gt, cmap='jet')
plt.title("Ground Truth")
plt.axis('off')
plt.show()

```


Dans cette étape, l'image hyperspectrale Indian Pines a été transformée en une matrice de données où chaque pixel est représenté par son vecteur spectral.

L'algorithme de classification non supervisée de type K-means a ensuite été appliqué afin de regrouper automatiquement les pixels présentant des signatures spectrales similaires. Les labels obtenus ont été reconstruits sous forme d'image afin de visualiser la carte de classification et de la comparer à la vérité terrain (ground truth).

On a comme résultat:

```
PS C:\Users\AssaneThiao\OneDrive\Documents\internship\code> python .\kmeans_classification.py
Image shape: (145, 145, 200)
Ground truth shape: (145, 145)
Dataset shape (pixels, bands): (21025, 200)
```

La visualisation donne :



Constat :


Je constate que plus on augmente le nombre de cluster, plus l'image reconstruite devient de plus en plus moins nette et moins proche de la structure attendue du ground truth.

J'ai aussi essayé de recoder moi-même la logique de K-means afin d'avoir davantage de contrôle sur les différentes étapes de l'algorithme (initialisation des centroïdes, calcul des distances, attribution des clusters et mise à jour des centroïdes).

L'objectif était de voir si une implémentation personnalisée pouvait permettre d'obtenir une meilleure reconstruction de l'image classifiée par rapport à l'implémentation standard de sklearn, ainsi que de mieux comprendre le comportement de l'algorithme sur les données hyperspectrales.

Mais, j'ai pratiquement les mêmes résultats

Custom K-Means Classification



Pour conclure cette semaine de travail, j'ai pu avancer sur la mise en place de la chaîne complète de classification non supervisée des images hyperspectrales. J'ai notamment chargé et analysé les données, effectué la transformation en matrice de pixels, appliqué

l'algorithme de K-means, puis reconstruit et visualisé les cartes de classification obtenues en les comparant au ground truth. Mais, les résultats ne sont pas bons.

À ce stade, je n'ai pas encore finalisé l'évaluation quantitative des résultats (notamment le calcul de l'accuracy), mais j'y pense afin de mieux mesurer la qualité des classifications obtenues.

Pour la suite, je souhaite approfondir le travail en mettant en place des méthodes complémentaires, notamment le region growing, afin d'améliorer la cohérence spatiale de la classification. L'objectif sera également d'améliorer la séparation des classes et la robustesse des résultats sur les pixels.

Je souhaiterais également, si possible, avoir votre avis et vos conseils sur la direction à suivre pour la suite du travail. J'ai commencé à explorer la classification non supervisée avec K-means, mais je pense qu'il serait utile de mieux structurer les prochaines étapes afin de progresser de manière plus efficace, notamment pour l'amélioration de la qualité des classifications et l'intégration de nouvelles méthodes comme le region growing.

Enfin, concernant l'accès à distance à mon poste, le problème est désormais résolu, il s'agissait simplement de l'unité centrale qui n'était pas allumée.