

Proposition de sujet de stage (1 mois et 29 jours)

Classification non-supervisée d'une image satellite hyperspectrale

Gabriel DAUPHIN

March 21, 2026

Une grande quantité d'images satellites sont aujourd'hui dans une certaine mesure disponibles, en grande partie grâce à de nombreux satellites. Elles diffèrent par la résolution spatiale (quelques mètres ou plus), la taille de la région observée, la fréquence à laquelle le même point est de nouveau observé et la sensibilité aux longueurs d'onde. On appelle images hyperspectrales, une image satellite où chaque point de l'image est décrit par une centaine de nombres qui correspondent à autant d'intensités associées à une longueur d'onde. Une bonne partie des longueurs d'onde concerne le domaine visible et le proche infrarouge, une partie concerne l'infrarouge moyen. Le fait de disposer d'une image hyperspectrale plutôt qu'une image couleur classique, permet par exemple de continuer à avoir certaines informations lorsqu'il y a des nuages, mais elle permet surtout d'avoir une connaissance plus fine des matériaux observés. Ainsi ces images hyperspectrales se présentent comme un tableau de nombres entiers dépendant de trois coordonnées, les deux premières indiquant la localisation et la troisième indiquant le numéro de la longueur d'onde.

L'objectif de l'analyse de ces images satellites est de pouvoir attribuer une signification à chaque point de l'image qui correspond à une portion de surface sur la Terre. Cette signification peut être le fait d'être une route, une étendue d'eau, un bâtiment, une surface cultivée avec une plante particulière à un état de son développement ou une portion de forêt. Ce processus est appelé classification. La difficulté tient à ce que dans la réalité, les portions de surfaces peuvent ne pas véritablement correspondre à une des catégories proposées, elle tient surtout au fait que les ondes réfléchies depuis cette région et leurs intensités pour les différentes longueurs d'onde ne dépendent pas que des coefficients d'absorption des matériaux, elles dépendent aussi de la lumière reçue par chaque région, y compris celle réfléchie par les zones voisines, et de l'angle de la surface des matériaux. La proportion qui arrive au satellite est modifiée par la possible absorption dans l'atmosphère. Enfin même si les coefficients d'absorption ne sont heureusement pas les mêmes pour chaque molécule, ils ont globalement une allure assez similaire vis-à-vis de la longueur d'onde.

Ces images donnent lieu à deux sujets de recherche, celui du recalage, c'est-à-dire l'appariement de chaque point avec une région de la Terre spécifique et celui de la classification, qui est l'objet du stage. Cette classification est un sujet de recherche depuis une quarantaine d'années. Cette classification suppose que pour une partie de l'image on ait attribué une signification à chaque portion de surface. On appelle cela labelliser les pixels et constituer une base d'entraînement. On cherche à généraliser à partir de ces points connus, la signification des autres points. C'est ce qu'on appelle la classification supervisée. J'observe qu'au fur et à mesure des années la proportion de points supposés connus diminue. Le sujet de stage consiste à chercher à faire cette classification sans aucun point connu, ce qu'on appelle la classification non-supervisée. C'est un sujet très étudié en apprentissage, mais je propose ici d'utiliser une spécificité des images satellites. Ces images étudiées représentent de vraies régions souvent aménagées et comme on peut l'observer avec google maps, il y a souvent des domaines avec des frontières qui sont rectilignes (routes, portion de surface cultivée) ou qui suivent la pente du terrain, une pente que je suppose ici connue.

Le stage consiste dans un premier temps à traduire en Python des expérimentations déjà faites en Matlab. Dans un deuxième temps, il s'agit de faire une proposition d'expérimentation adaptée à une image satellite, à l'implémenter et à la comparer avec d'autres algorithmes déjà publiés dans la littérature.